

## 05 卡尔曼滤波(理解与实践)


### ● 卡尔曼滤波

#### □ 多维卡尔曼滤波

- $\mathbf{Q}_k \sim \mathcal{N}(0, \mathbf{\Sigma}_{\mathbf{Q}_k})$ ,  $\mathbf{R}_k \sim \mathcal{N}(0, \mathbf{\Sigma}_{\mathbf{R}_k})$ ,  $\mathbf{x}_{k-1}^+ \sim \mathcal{N}(\boldsymbol{\mu}_{k-1}^+, \mathbf{\Sigma}_{k-1}^+)$
- 状态方程:  $\mathbf{X}_k = \mathbf{F}\mathbf{X}_{k-1} + \mathbf{Q}_k$
- 观测方程:  $\mathbf{Y}_k = \mathbf{H}\mathbf{X}_k + \mathbf{R}_k$

#### 卡尔曼滤波

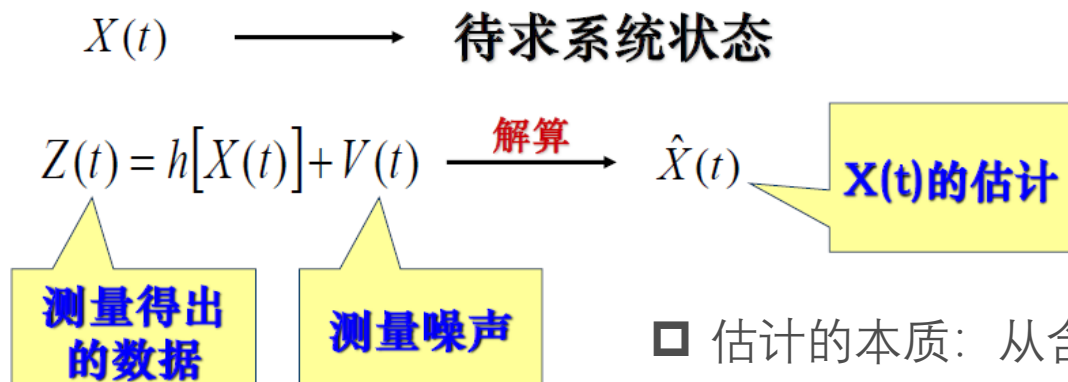
- (1) 一步预测状态:  $\boldsymbol{\mu}_k^- = \mathbf{F}\boldsymbol{\mu}_{k-1}^+$
- (2) 一步预测方差:  $\mathbf{\Sigma}_k^- = \mathbf{F}\mathbf{\Sigma}_{k-1}^+\mathbf{F}^T + \mathbf{\Sigma}_{\mathbf{Q}_k}$
- (3) 更新卡尔曼增益:  $\mathbf{K}_k = \mathbf{\Sigma}_k^- \mathbf{H}^T (\mathbf{H}\mathbf{\Sigma}_k^- \mathbf{H}^T + \mathbf{\Sigma}_{\mathbf{R}_k})^{-1}$
- (4) 更新状态:  $\boldsymbol{\mu}_k^+ = \boldsymbol{\mu}_k^- + \mathbf{K}_k(\mathbf{y}_k - \mathbf{H}\boldsymbol{\mu}_k^-)$
- (5) 更新方差:  $\mathbf{\Sigma}_k^+ = (\mathbf{I} - \mathbf{K}_k \mathbf{H})\mathbf{\Sigma}_k^-$



## 05 卡尔曼滤波(理解与实践)

### ● “最优估计”的理解

#### □ 什么是估计?



□ 估计的本质：从含有噪声的量测信息中提取出有用的信息


#### □ 估计的三种表现形式

设在 $[t_0, t_1]$ 时间段内量测为 $Z$ ，待求状态为 $X(t)$

当 $t=t_1$ 时， $\hat{X}(t)$ 称为 $X(t)$ 的估计；

当 $t>t_1$ 时， $\hat{X}(t)$ 称为 $X(t)$ 的预测；

当 $t<t_1$ 时， $\hat{X}(t)$ 称为 $X(t)$ 的平滑。



## 05 卡尔曼滤波(理解与实践)

- “最优估计”的理解

- 什么是最优估计?



则所得估计为**最优估计**！ □ 估计的本质：从含有噪声的量测信息中提取出有用的信息

- 估计准则

如上所述,所谓估计问题,就是要构造一个观测数据  $Z$  的函数  $X(Z)$  来作为被估计量  $X(t)$  的一个估计量。我们总希望估计出来的参数或状态变量愈接近实际值愈好。为了衡量估计的好坏,必须要有一个衡量的标准,这个衡量标准就是估计准则。估计常常是以“使估计的性能指标达到极值”作为准则的。估计准则可以是多种多样的。常用的估计准则有:最小方差准则、极大似然准则、极大验后准则、线性最小方差准则、最小二乘准则等。

## 05 卡尔曼滤波(理解与实践)


### ● “最优估计”的理解

□ 估计准则1: 最小二乘估计及其推广

使各量测量  $Z_i$  与由估计  $\hat{X}$  确定的量测估计

$\hat{Z}_i = H_i \hat{X} + V_i$  之差的平方和最小, 即:

$$J(\hat{X}) = (Z - H\hat{X})^T (Z - H\hat{X}) = \min$$


$$\left. \frac{\partial J}{\partial X} \right|_{X=\hat{X}} = -2H^T (Z - H\hat{X}) = 0$$

若  $H$  有最大秩  $n$ , 即  $H^T H$  正定, 且  $m = \sum_{i=1}^r m_i > n$ , 则

$$\hat{X} = (H^T H)^{-1} H^T Z$$

线性估计

特点:

- 最小化量测误差的平方和
- 兼顾所有方程的近似程度, 使整体误差最小, 有利于抑制噪声
- 无偏估计

假设: 量测噪声  $V$  是零均值噪声, 方差为  $R$  的随机向量

(1) 最小二乘估计是无偏估计

$$E[\hat{X}] = X \text{ 或}$$

$$E[\tilde{X}] = 0, \text{ 式中 } \tilde{X} = X - \hat{X}, \text{ 为 } X \text{ 的估计误差}$$

(2) 最小二乘的均方误差阵

$$E[\tilde{X}\tilde{X}^T] = (H^T H)^{-1} H^T R H (H^T H)^{-1}$$

## 05 卡尔曼滤波(理解与实践)

### ● “最优估计”的理解

▣ 估计准则1: 最小二乘估计及其推广

▣ 加权最小二乘的指标函数

$$J(\hat{X}) = (Z - H\hat{X})^T W (Z - H\hat{X}) = \min$$

正定加权矩阵

成立, 应满足

$$\left. \frac{\partial J}{\partial X} \right|_{X=\hat{X}} = -H^T (W + W^T) (Z - H\hat{X}) = 0$$

$$\hat{X} = [H^T (W + W^T) H]^{-1} H^T (W + W^T) Z$$

通常W取为对称阵, 即 $W^T = W$ , 则加权最小二乘估计为:

$$\hat{X} = [H^T (W) H]^{-1} H^T (W) Z$$

特点:

- 加权最小二乘也是无偏估计
- 最优加权最小二乘估计

$$\tilde{X} = X - \hat{X} = -(H^T W H)^{-1} H^T W V$$

量测  
误差

若V的均值为零, 方差阵为R, 则:

加权最小二乘估计也是无偏估计!

估计的均方差为:

$$E(\tilde{X}\tilde{X}^T) = (H^T W H)^{-1} H^T W R W H (H^T W H)^{-1}$$

若 $W = R^{-1}$ , 则加权最小二乘估计为:

$$\hat{X} = (H^T R^{-1} H)^{-1} H^T R^{-1} Z$$

马尔可夫  
估计

马尔可夫估计的均方误差为:

$$E(\tilde{X}\tilde{X}^T) = (H^T R^{-1} H)^{-1}$$

- ▣ 比其他加权最小二乘估计均方差都小
- ▣ 最优的加权最小二乘估计

## 05 卡尔曼滤波(理解与实践)

### ● “最优估计”的理解

▣ 估计准则1: 最小二乘估计及其推广

▣ 由前k次量测值确定的加权最小二乘估计为:

$$\hat{X}_k = (\overline{H_k^T \bar{W}_k \bar{H}_k})^{-1} \overline{H_k^T \bar{W}_k \bar{Z}_k}$$

令  $P_k$

▣ 由前k+1次量测值确定的加权最小二乘估计为:

$$\hat{X}_{k+1} = (\overline{H_{k+1}^T \bar{W}_{k+1} \bar{H}_{k+1}})^{-1} \overline{H_{k+1}^T \bar{W}_{k+1} \bar{Z}_{k+1}}$$

推导得:

$$P_{k+1} = P_k - P_k H_{k+1}^T (W_{k+1}^{-1} + H_{k+1} P_k H_{k+1}^T)^{-1} H_{k+1} P_k$$

$$\hat{X}_{k+1} = \hat{X}_k + P_{k+1} H_{k+1}^T W_{k+1} (Z_{k+1} - H_{k+1} \hat{X}_k)$$

特点:

- 采用批处理实现的最小二乘算法, 需存储所有量测值
- 递推最小二乘估计从每次获得的量测值中提取出被估计量的信息, 用于修正上一步所得的估计
- 获得量测的次数越多, 修正的次数也越多, 估计精度也越高

- ▣ 只要给定初始值 $X_0$ 和 $P_0$ , 就能获得 $X$ 在任意时刻的最小二乘估计;
- ▣ 初始值 $X_0$ 和 $P_0$ 可以任意选取, 随着量测次数的增加, 初值影响逐渐消失, 估计值逐渐趋于稳定而逼近被估计量。

## 05 卡尔曼滤波(理解与实践)

### ● “最优估计”的理解

#### □ 估计准则1：最小二乘估计及其推广

#### □ 最小二乘估计优、缺点

类别：

- 最小二乘估计
- 加权最小二乘估计
- 最优加权最小二乘估计
- 递推最小二乘估计

优点：

算法简单，特别是一般最小二乘估计，不必知道与被估计量及量测量有关的任何统计信息。

缺点：

- 只能估计确定性的常值向量，而无法估计随机向量的时间过程；
- 最优指标只保证了量测的估计均方误差之和最小，而并未确保被估计量的估计误差达到最佳，故估计精度不高。

$$J(\hat{X}) = (Z - H\hat{X})^T W (Z - H\hat{X}) = \min$$



## 05 卡尔曼滤波(理解与实践)

### ● “最优估计”的理解

□ 估计准则2：最小方差估计及其推广

特点：

- 无偏估计
- 最小方差即为估计误差的方差
- 通常比较难计算，

□ 最小方差估计的估计准则是估计的均方误差最小，即：

**Z是m维随机量测向量**

$$E\{[X - \hat{X}(Z)]^T [X - \hat{X}(Z)]\} \leq E\{[X - \Gamma(Z)]^T [X - \Gamma(Z)]\}$$

**估计均方差阵**

**根据其他方法用Z计算得到的X的估值**

□ 最小方差估计的误差小于等于其他估计的均方误差！

□ 最小方差估计具有无偏性质，即它的估计误差（亦可用  $\tilde{X}$  表示）的均值为零。即：

$$E\{[X - \hat{X}(Z)]\} = E\{\tilde{X}\} = 0$$

□ 估计的均方误差就是估计误差的方差，即：

$$E\{\tilde{X}\tilde{X}^T\} = E\{[\tilde{X} - E(\tilde{X})][\tilde{X} - E(\tilde{X})]^T\}$$

□ 因此，最小方差估计不但使估值  $\hat{X}(Z)$  的均方误差最小，而且这种最小的均方误差就是估计的误差方差



## 05 卡尔曼滤波(理解与实践)

- “最优估计”的理解

- 估计准则2：最小方差估计及其推广

- 如果将估值  $\hat{X}$  规定为量测矢量  $Z$  的线性函数，即

$$\hat{X} = AZ + b$$

特点：

- 实用性较高，可以计算

- 式中  $A$  和  $b$  分别是  $(n \times m)$  阶和  $n$  维的矩阵和矢量。这样的估计方法称为**线性最小方差估计**。

- 可证明，这种估计只需要被估计值  $X$  和量测值  $Z$  的一、二阶统计特性，所以，它比最小方差估计较为实用。

## 05 卡尔曼滤波(理解与实践)

- “最优估计”的理解

- 估计准则3： 概率相关估计

- 贝叶斯估计

- 使贝叶斯风险达到最小的估计

- 极大似然估计

- 使关于条件概率密度的似然函数达到极大的估计

- 极大验后估计

- 使验后概率密度函数达到极大的估计

## 05 卡尔曼滤波(理解与实践)

### ● “最优估计”的理解

#### □ 估计准则对比

##### □ 最小二乘估计

适用于对常值向量或随机向量的估计。

**优点：**算法简单，对被估计量和量测误差缺乏了解时仍能适用。

**缺点：**最优指标为量测估计精度达到最佳，估计中不使用被估计量和量测误差的统计信息，估计精度不高。

##### □ 最小方差估计

**优点：**所有估计中估计的均方误差为最小的估计，是所有估计中的最佳者。

**缺点：**只确定估计值是被估计量在量测空间上的条件均值这一抽象关系。而按条件均值的一般求法求取最小方差估计非常困难。

##### □ 线性最小方差估计

适用于随机过程的估计。

**优点：**所有线性估计中的最优者，估计过程中只需知道被估计量和量测量的一阶和二阶距。

**缺点：**平稳过程的一阶和二阶距都为常值，而非平稳过程的一阶和二阶距随时间变化，必须知道每一估计时刻的一阶和二阶距才能求出估计值，这一要求太苛刻。**故线性最小方差估计适用于平稳过程而难以适用非平稳过程。**

##### □ 极大验后估计、贝叶斯估计、极大似然估计

与条件概率密度有关，计算困难。

特点：


- 可实现，估计方差小：线性最小方差估计
- 实时性：递推

卡尔曼滤波

## 05 卡尔曼滤波(理解与实践)

### ● 卡尔曼滤波理解

#### □ 连续卡尔曼滤波



特点:

- 微分黎卡提方程的解 $P$ (在远离无限时域内稳定, 初值扰动的影响较小, 很快收敛), 对卡尔曼增益 $K$ 的响应较小
- $Q$ 通过影响 $P$ 来影响 $K$ ,  $R$ 直接影响 $K$
- $QR^{-1}$ 正相关 $K$ , 增大导致卡尔曼滤波倾向于观测值, 减小导致卡尔曼滤波倾向于预测值
- $R$ 一般由传感器获取,  $Q$ 是可调参数

- 但也可以直接从连续系统的滤波方程求出系统状态的估值, 设连续系统的状态方程和量测方程分别为:

$$\dot{X}(t) = F(t)X(t) + G(t)W(t)$$

$$Z(t) = H(t)X(t) + V(t)$$

- $X(t)$ 和 $Z(t)$ 分别为 $t$ 时刻的系统状态矢量和量测矢量;
- $F(t)$ ,  $G(t)$ 和 $H(t)$ , 分别为系统矩阵, 系统噪声矩阵和量测矩阵;
- $W(t)$ 和 $V(t)$  和分别为系统噪声矢量和量测噪声矢量, 卡尔曼滤波要求它们都是零均值的白噪声过程。
- 根据估计均方误差最小的估计准则, 按上述系统和量测值, 可以推导出连续系统的滤波方程, 即

$$\begin{cases} K(t) = P(t)H^T(t)R^{-1}(t) \\ \dot{\hat{X}}(t) = F(t)\hat{X}(t) + K(t)[Z(t) - H(t)\hat{X}(t)] \\ \dot{P}(t) = P(t)F^T(t) + F(t)P(t) - P(t)H^T(t)R^{-1}(t)H(t)P(t) + G(t)Q(t)G^T(t) \end{cases}$$

- $R^{-1}(t)$ 为是量测噪声的方差强度阵  $R(t)$ 的逆阵, 即

$$E\{V(t)V^T(\tau)\} = R(t)\delta(t - \tau)$$

- $Q(t)$ 是系统噪声的方差强度阵, 即

$$E\{[G(t)W(t)][G(\tau)W(\tau)]^T\} = G(t)Q(t)G^T(\tau)\delta(t - \tau)$$

## 05 卡尔曼滤波(理解与实践)

### ● 卡尔曼滤波理解

#### □ 参数稳定性

特点:

#### ➤ 协方差正定性的保证

$$\begin{aligned} P_k^+ &= (I - K_k H_k) P_k^- (I - K_k H_k)^T + K_k R_k K_k^T \\ &= [ (P_k^-)^{-1} + H_k^T R_k^{-1} H_k ]^{-1} \\ &= (I - K_k H_k) P_k^- \end{aligned} \tag{5.19}$$

上面  $P_k^+$  的第一个表达式叫做协方差量测更新方程的 Joseph 稳定形式。它是 Peter Joseph 在 1946 年创立的,比  $P_k^+$  的第三个表达式表现得更稳定、鲁棒性更好 [Buc68, Cra04] (见习题 5.2)。只要  $P_k^-$  是对称的正定阵,那么  $P_k^+$  的第一个表达式保证了  $P_k^+$  将一直是对称的正定阵。 $P_k^+$  的第三个表达式比第一个表达式计算简单,但是它的形式不能确保  $P_k^+$  是对称的或是正定阵。 $P_k^+$  的第二个表达式很少用到,但是它将用于 6.2 节中信息滤波器的推导。


## 05 卡尔曼滤波(理解与实践)

### ● “数据融合”的理解

#### ▣ 预测与量测的数据融合

特点:


- 多个数据比单个数据要好, 不要剔除所谓的低精度数据: 将**不准确的测量与不准确的系统模型混合**得到的估计比信息源本身更好
- 预测: 基于上一步估计值与系统模型
- 更新: 基于预测值与观测值做融合(估计处于两者之间), 融合比例取决于两者的精度(方差)
- 估计值: 用期望描述



## 05 卡尔曼滤波(理解与实践)

### ● g-h滤波

□ Example: 体重




融合增益:  $g = 0.4$

$$\text{estimate} = \text{prediction} + \frac{4}{10}(\text{measurement} - \text{prediction})$$


实际体重模型:  $dx = 1$

方案1: 预测模型:  $dx = 1$ , 每天增加1lb



结论: 当预测模型较准时, 滤波效果较好, 估计值能够很好的跟踪真实值

方案2: 预测模型:  $dx = -1$ , 每天减小1lb




结论: 当预测模型很不准时, 滤波效果很差, 估计值虽然能够有跟踪趋势, 但跟踪速度很慢



## 05 卡尔曼滤波(理解与实践)

### ● g-h滤波

□ Example: 体重



融合增益:  $g = 0.4$


$$\text{estimate} = \text{prediction} + \frac{4}{10}(\text{measurement} - \text{prediction})$$

实际体重模型:  $dx = 1$

方案3: 利用观测与估计值修正预测模型

$$\text{new gain} = \text{old gain} + \frac{1}{3} \frac{\text{measurement} - \text{predicted weight}}{1 \text{ day}}$$

修正增益:  $h = 0.4$




结论: 初始模型不正确导致前期误差较大, 修正预测模型后后期误差较小

## 05 卡尔曼滤波(理解与实践)

### ● g-h滤波

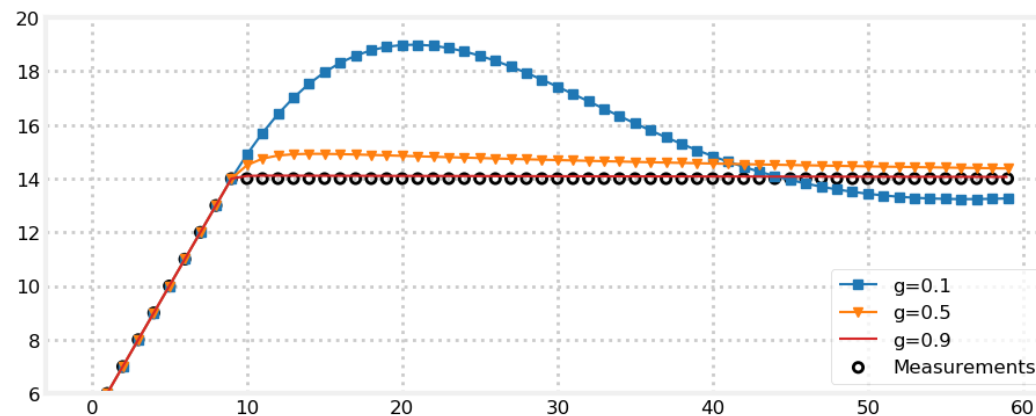
#### □ Example: 变增益g

变增益g, 增加



结论：增益 $g$ 越大，越接近于量测值，滤波结果几乎等同于量测而没有任何噪声的消除作用

变增益g, 减小



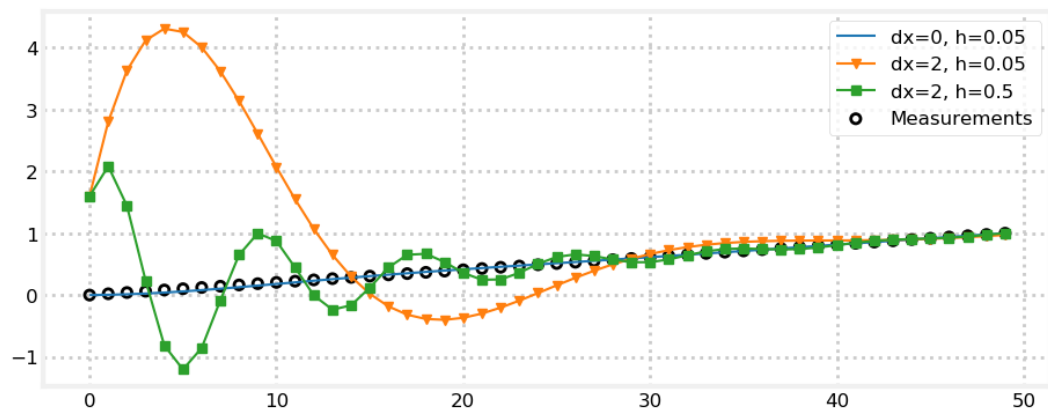
结论：增益 $g$ 越大，越接近于预测值，可以滤掉噪声，但信号变化也无法跟踪上

## 05 卡尔曼滤波(理解与实践)

### ● g-h滤波

#### □ Example: 变增益h

变增益h，是对状态的预测与量测变化率的权衡，h很大时能够跟踪这种变化，反之不行



结论：增益h越大，跟踪变换能力越强(超调小)，但随着震荡也会变大